

7반 1조 EDA Finding Report

P214-문관록, P215-박기연, P222-신소영, P227-이준영, P232-임채현, P239-최광원

Answer 1: 데이터 구조에서 확인한 특징

- Finding:
 - 데이터는 2930개 행, 15개 열(수치형 11개, 범주형 4개)로 구성되어 있고, Target은 SalePrice.
 - (1) `Garage_Cars`(차고에 주차 가능수) , `Garage_Yr_Blt`(차고가 지어진 연도) 가 정수형이어야 할 것 같은데 float64로 되어 있다.
 - (2) `Overall_Qual`(집 전체의 품질) , `Overall_Cond`(집 전체의 컨디션) 는 int64지만 실제로는 1~10 등급을 나타내는 범주형 변수에 가깝다.
- Evidence:
 - Data shape : (2930, 15)
 - Data types :

<code>Garage_Cars</code>	float64
<code>Garage_Yr_Blt</code>	float64
<code>Overall_Qual</code>	int64
<code>Overall_Cond</code>	int64
- Possible Action:
 - (1) Garage 관련 두 변수가 float인 이유가 결측치 때문일 가능성이 있으므로, 결측치 확인 단계에서 검증 필요하다.
 - (2) 회귀분석에 그대로 쓸지 범주형으로 다룰지 나중에 판단 필요하다

Answer 2: 결측치 있는 변수 & 결측의 가능한 의미

- Finding:
 - 전체 2,930개 주택 데이터 중 160개 행에서 결측치가 확인되었으며, 결측값은 총 161개이다.
 - 변수별로는 `Garage_Yr_Blt` 에서 159건, `Garage_Cars` 에서 1건, `Total_Bsmt_SF` 에서 1건의 결측치가 확인되었다. 이 중 `Garage_Cars` 와 `Garage_Yr_Blt` 가 동시에 결측인 행이 1건 존재한다.
- Evidence:
 - `Garage_Yr_Blt` 결측 159건 중 157건은 `Garage_Cars = 0` 으로, 차고가 없는 주택에서 차고 건축연도가 비어 있는 패턴이 확인되었다.
 - 나머지 2건 중 1건은 `Garage_Cars = 1` 인데 `Garage_Yr_Blt` 만 결측이고, 다른 1건은 `Garage_Cars` 와 `Garage_Yr_Blt` 가 동시에 결측이다.
 - `Total_Bsmt_SF` 는 1건의 결측이 존재하며, 데이터에 `Total_Bsmt_SF = 0` 인 주택이 별도로 존재하므로 단순히 지하실이 없다는 의미로 보기는 어렵다.
- Possible Action:
 - `Garage_Yr_Blt` 의 157건은 차고가 없는 데서 발생한 구조적 결측으로 볼 수 있으므로, 평균이나 중앙값으로 임의 대체하기보다 '차고 없음'이라는 의미를 유지하는 방향으로 처리한다.
 - 나머지 결측은 실제 정보 누락 가능성이 있으므로 관련 변수나 원본 데이터를 추가 확인한 뒤 대체 또는 제거 여부를 결정한다.

Answer 3: Target 분포 특징 & 향후 고려할 변환

- Finding:
 - 오른쪽으로 긴 꼬리를 가진 분포. 평균값은 대표값의 역할 못할 가능성이 큼 (고가의 주택이 분포의 꼬리를 길게 만듦)
- Evidence:
 - 평균 180796.06, 중앙값 160000, 왜도 1.74, IQR 상한을 초과한 고가 건물 137건 (4.68%)
- Possible Action:
 - $\ln(1 + x)$ (aka. $\log 1p$) 후 왜도 -0.01 $\rightarrow$ log scale을 통해 오른쪽 꼬리의 아웃라이어를 효과적으로 억제할 수 있었음. 따라서 $\log 1p(\text{SalePrice})$ 로 학습하고 $e^x - 1$ (aka. $\exp m1$)을 통해 수치 복원. 평가에는 RMSLE, 요약 및 수치 보고에는 중앙값을 사용.

Answer 4: 이상치 후보 확인된 변수 & 처리 전 확인할 사항

- Finding:
 - 3개 변수(`Lot_Area` , `Total_Bsmt_SF` , `Gr_Liv_Area`)에서 IQR 상한을 초과하는 강한 오른쪽 쏠림(Right-Skewed)
- Evidence:
 - `Lot_Area` (127개, 4.33%), `Total_Bsmt_SF` (123개, 4.2%), `Gr_Liv_Area` (75개, 2.56%) 순으로 다수 존재.

- Possible Action:
 - **오류/실제 데이터 구분:** 단순 입력 오류가 아닌 '초고가 대형 주택' 가능성이 높으므로 무조건 삭제 금지.
 - **다변량 선별 제거:** 면적(`Gr_Liv_Area`) 대비 가격(`SalePrice`)이 비정상적으로 낮은 특이점만 선별 제거.
 - **로그 변환 적용:** 면적 변수에 로그 변환($\log 1p$)을 적용해 왜도와 스케일 불균형 완화.

Answer 5: 주택가격과 관계가 강해 보이는 수치형 변수

- Finding:
 - `Overall_Qual` (전체 품질)과 `Gr_Liv_Area` (지상 생활면적)가 `SalePrice`와 가장 강한 관계를 보임
 - 이후 아래의 `Garage_Cars` , `Total_Bsmt_SF` , `Year_Built` 의 순서를 따름
- Evidence:
 - Correlation_with_SalePrice 표 & Correlation Heatmap
 - Overall_Qual(품질) 0.8 > Gr_Liv_Area(생활 면적) 0.71 > Garage_Cars(차고 주차 가능 대수) 0.65
 - 반대로 `Overall_Cond` (주택 상태)는 상관 -0.10으로 거의 무관한 비단조형 패턴을 보인다. `Overall_Qual` (품질)과 이름은 비슷하지만 전혀 다른 정보를 담고 있다는 뜻이다.
- Possible Action:
 - `Overall_Qual` , `Gr_Liv_Area` 를 회귀모델의 핵심 입력 변수로 우선 채택한다.
 - `Overall_Cond` 처럼 선형 상관이 낮은 변수도 등급별 평균/중앙값 비교나 트리 기반 모델(비선형 관계 포착 가능)로 재검증한 뒤 변수 배제 여부를 최종 결정한다.

Answer 6: 가격 차이가 뚜렷하게 나타나는 범주형 변수

- Finding:
 - `Neighborhood` (지역), `Kitchen_Qual` (주방 품질), `Exter_Qual` (외장 품질) 세 변수 모두에서 범주 간 가격 차이가 뚜렷하다.
- Evidence:
 - SalePrice by Neighborhood BoxPlot
 - `Neighborhood` 별 중앙가격:
 - 낮은 지역: `MeadowV` 88,250(37건), `BrDale` 106,000(30건), `IDOTRR` 106,500(93건)
 - 높은 지역: `NoRidge` 302,000(71건), `NridgHt` 317,750(166건), `StoneBr` 319,000(51건)
 - `Kitchen_Qual` 별 중앙가격:
 - `Fa` : 107,750(70건)
 - `TA` : 136,500(1,494건)
 - `Gd` : 201,000(1,160건)
 - `Ex` : 325,624(205건)
 - `Exter_Qual` 별 중앙가격:
 - `Fa` : 85,000(35건)
 - `TA` : 139,000(1,799건)
 - `Gd` : 219,500(989건)
 - `Ex` : 370,967(107건)
 - 품질 등급이 상승할수록 가격도 상승하는 패턴이 실제 그룹별 중앙값에서 확인됨.
- Possible Action:
 - `Neighborhood` , `House_Style` 처럼 순서가 없는 변수는 원-핫 인코딩을 적용한다.
 - `Kitchen_Qual` , `Exter_Qual` 은 품질 순서가 있으므로 순서형 인코딩과 원-핫 인코딩의 모델 성능을 비교한다.
 - 범주형 변수의 효과는 면적·품질·건축연도와 함께 모델에 넣어 평가한다. 예를 들어 높은 가격의 지역이 단순히 더 넓고 품질 좋은 주택이 많은 결과일 수도 있으므로, 범주별 중앙가격만으로 지역의 독립적 효과라고 단정하지 않는다.

Answer 7: 향후 전처리 단계에서 수행해야 할 작업

- Finding:
 - (1) Garage 관련 두 변수(`Garage_Cars` , `Garage_Yr_Blt`)가 float인 이유가 결측치 때문일 가능성이 있으므로, 결측치 확인 단계에서 검증 필요.
 - (2) `Overall_Cond` , `Overall_Qual` 을 회귀분석에 그대로 쓰지 범주형으로 다룰지 판단 필요.

- (3) Target과 면적의 왜도에 오른쪽 치우침 존재
- Evidence:
 - Answer 1~6
- Possible Action:
 - (1) 결측 발생에 뚜렷한 의미나 패턴이 없는 소수의 행은 전체 데이터에서 차지하는 비율이 매우 낮으므로 분석 대상에서 제외한다. 반면 `Garage_Yr_Blt` 처럼 차고가 없어 발생한 구조적 결측은 제거하지 않고, 차고 존재 여부를 나타내는 별도 변수를 추가하여 해당 정보를 유지한 채 분석에 활용한다.
 - (2) `Overall_Qual` 은 점수가 5에서 10으로 증가할 때 중앙가격도 133,000에서 451,950으로 일관되게 상승하므로, 순서를 유지한 수치형(순서형) 변수로 사용한다. `Overall_Cond` 는 상관계수가 0.10으로 가격과의 선형 관계가 매우 약하므로 기본 모델에서는 우선 제외하고, 필요하면 비선형 효과나 다른 변수와의 상호작용이 있는지 추가 검증한다.
 - (3) `SalePrice` , `Lot_Area` 등의 변수에 $\log(x + 1)$ 후 학습, 수치 보고를 위해 $e^x - 1$ 로 복원.