

7반 1조 Feature Engineering

P214-문관록, P215-박기연, P222-신소영, P227-이준영, P232-임채현, P239-최광원

[Question 1]

- Target 변수와 설명변수는 무엇인가? `SalePrice`
- 결측치가 있는 변수는 무엇인가? `Garage_Yr_Blt`, `Garage_Cars`, `Total_Bsmt_SF`
- 수치형 변수와 범주형 변수는 각각 몇 개인가? `11/4`
- 이후 단계에서 어떤 변수를 전처리해야 할 것으로 예상되는가? `Garage_Yr_Blt`

[Question 2]

- 결측치가 있는 변수는 무엇인가?
 - Train 기준 `Garage_Yr_Blt : 122건`, `Total_Bsmt_SF : 1건`, `Garage_Cars : 1건`
- 수치형 변수에는 평균, 중앙값, 0 중 어떤 방식이 적절한가?
 - 중앙값, `Garage_Yr_Blt : 2207` → 차고 건설 연도가 2207년 이라는 극단적 입력 오류 존재함.
- 범주형 변수에는 최빈값과 Missing 중 어떤 방식이 적절한가?
 - 범주형 변수에는 결측 없음

[Question 3]

- 이상치를 제거하면 학습데이터 수는 어떻게 달라지는가?
 - 학습 데이터 수를 줄이지만, 이번 실습에서는 행 제거 없이 Clip을 사용했으므로 Train 행 수는 2,344개로 유지
- Clip은 이상치를 어떤 값으로 바꾸는가?
 - Clip은 IQR 기준 밖의 값을 경계값으로 바꿈
- 실제 대형 주택을 이상치로 처리해도 되는가?
 - 안됨 → 데이터 손실 및 편향, 테스트 데이터와의 불일치

Reports

무엇을?

`Target Log Scale`

- `log_target : True`
- `SalePrice` 를 $\ln(x+1)$ 로 바꿔 학습. $e^x - 1$ 로 원래 가격 단위로 되돌림

어떤 변화를 기대했나?

- `SalePrice` 는 오른쪽 꼬리가 긴 분포. Log Scale을 통해 분포가 대칭에 가까워짐
- 소수 고가 주택이 학습을 끌고가는 문제를 줄여 MAE와 RMSE 모두 낮아질 것

실제로 어떤 변화?

- Train 기준 Skewness가 1.75 에서 -0.09로 바뀜

	기본 분할 MAE	기본 분할 RMSE	20분할 MAE	20분할 RMSE
로그변환 전	18,064	30,584	18,278	28,292
로그변환 후	16,124	27,911	16,418	26,851

- MAE는 20번 분할 모두에서 좋아졌지만, RMSE는 20번 중 14번만 좋아졌다.
- 극단 사례도 확인. 생활면적 5,642 sq ft인데 160,000달러에 팔린 주택은 로그변환만 한 모델에서 729,471달러로 예측됐다.

결과에서 확인한 것

- `SalePrice` 로그 변환은 타깃의 심한 양의 왜도를 효과적으로 제거했고, MAE를 모든 분할에서 개선시켜 전반적인 예측 안정성을 높였다.
- RMSE 역시 평균적으로 감소했으나 일부 분할에서는 악화되었으며, 극단적인 주택에서는 큰 예측 오차가 남았다.
- 따라서 로그 변환은 일반적인 주택 가격 예측 성능 개선에는 효과적이지만, 이상치나 특이한 Feature-Price 관계까지 해결하는 방법은 아니다.

- 추가적으로 이상치 처리, Feature Engineering, Robust 모델링 등을 함께 고려할 필요가 있다.

무엇을?

`Gr_Liv_Area`, `Lot_Area`의 이상치 처리를 `clip`에서 `remove`, `none`으로 비교

- IQR 배수는 1.5로 같다.

어떤 변화를 기대했나?

- `remove`는 극단값 행을 지워 Train을 깨끗하게 만드니 `clip`보다 좋거나 비슷할 것으로 기대했다.
- `none`은 극단값이 그대로 남아 가장 나쁠 것으로 예상했다.

실제로 어떤 변화?

처리	Train 행 수	기본 분할 RMSE	기본 분할 Adj R ²	20분할 MAE	20분할 RMSE
clip	2,344	27,514	0.90	16,427	25,846
none	2,344	34,625	0.84	16,765	30,106
remove	2,186	42,932	0.75	16,582	35,128

- 기대와 달리 `remove`가 가장 나빴다. Train에서 158행이 빠졌다.
- 기본 분할 Test에서 생활면적 상위 15채의 MAE는 `clip` 64,083, `none` 69,900, `remove` 96,044였다.
- MAE 차이는 수백 달러로 작았고, RMSE 차이는 수천~만 달러로 컸다. 일부 주택에서 큰 오차가 났다는 뜻이다.

결과에서 확인한 것

- `remove`는 Train에서만 행을 지우고 Test는 그대로 둔다.
- 그래서 모델이 한 번도 보지 못한 대형 주택이 Test에 들어오면, 로그 Target 모델의 예측이 크게 틀렸다.
- “이상치를 지우면 좋아진다”는 직관은 평가 데이터에도 같은 극단값이 들어온다는 점을 놓친다.
- 추가로 `Gr_Liv_Area`만 `clip`한 경우(20분할 RMSE 25,768)가 둘 다 `clip`보다 조금 좋았다. 로그변환으로 이미 꼬리가 눌린 변수에는 `clip`이 추가로 필요하지 않았다.

무엇을?

- `scaling_method`를 `standard`, `none`, `robust`, `minmax`로 바꿨다.
- 스케일링 대상은 연속형 5개와 순서형 수치 5개로 같다.

어떤 변화를 기대했나?

- 면적·연도·개수처럼 단위가 크게 다른 변수를 맞추면 회귀 성능이 좋아질 것으로 기대했다.
- 방법마다 결과도 조금씩 다를 것으로 예상했다.

실제로 어떤 변화?

- `LinearRegression`에서는 네 방법 모두 MAE 16,251, RMSE 27,514로 완전히 같았다. 예측값 차이는 약 2e-8로 부동소수점 오차 수준이었다.
- 대신 계수가 달라졌다.

변수	원래 단위 계수	Standard 후 계수
<code>Lot_Area</code>	0.12	0.05
<code>Gr_Liv_Area</code>	0.00	0.16

- 규제가 있는 `Ridge(alpha=10)`로 바꾸면 20분할 RMSE가 달라졌다.

스케일링	none	Standard	Robust	MinMax
20분할 RMSE	26,026	26,000	25,987	26,558

결과에서 확인한 것

- 규제 없는 선형회귀는 변수 크기를 바꾸면 계수가 반대로 조정돼 예측이 변하지 않는다.
- 이 모델에서 스케일링이 주는 효과는 성능이 아니라 계수를 서로 비교할 수 있게 해 주는 것이다. 원래 단위로는 `Lot_Area`가 더 중요해 보였지만, 표준화하니 `Gr_Liv_Area`가 가장 컸다.
- 규제나 거리를 쓰는 모델에서는 스케일링이 성능 자체를 바꾼다.

- MinMax는 `Garage_Yr_Blt` 의 입력 오류 2207처럼 최댓값 하나에 범위가 좌우돼 가장 나뻐던 것으로 추정한다.
- 즉 스케일링이 필요한지는 사용하는 모델에 따라 달라진다.